

Table 7: Results for Follow-Up Probe at a 1% false-positive rate on alpaca. The values in the AVERAGE column are computed by first aggregating across models and then across datasets.

Model (all instruction-tuned)	Dataset							AVERAGE
	HP-C	HP-KR	CG	ST	ID	GS	IT	
AUROC								
Llama 3.3 70B	0.50	0.14	0.75	0.61	0.93	0.24	0.85	0.57
Qwen 2.5 72B	0.50	0.52	—	0.55	0.83	—	—	0.60
Mistral 3.1 24B	0.68	0.54	—	0.88	0.89	0.61	0.65	0.71
Gemma 3 27B	—	—	0.75	—	0.60	—	0.71	0.69
Average	0.56	0.40	0.75	0.68	0.81	0.43	0.74	0.62
BALANCED ACCURACY AT 1% FPR								
Llama 3.3 70B	0.50	0.26	0.60	0.57	0.87	0.35	0.66	0.54
Qwen 2.5 72B	0.50	0.50	—	0.50	0.78	—	—	0.57
Mistral 3.1 24B	0.51	0.50	—	0.71	0.83	0.50	0.49	0.59
Gemma 3 27B	—	—	0.50	—	0.54	—	0.55	0.53
Average	0.50	0.42	0.55	0.60	0.76	0.42	0.56	0.54
BALANCED ACCURACY AT 0.1% FPR								
Llama 3.3 70B	0.50	0.30	0.75	0.50	0.89	0.43	0.68	0.58
Qwen 2.5 72B	0.50	0.50	—	0.50	0.79	—	—	0.57
Mistral 3.1 24B	0.60	0.50	—	0.65	0.83	0.50	0.58	0.61
Gemma 3 27B	—	—	0.50	—	0.50	—	0.60	0.53
Average	0.53	0.43	0.62	0.55	0.75	0.47	0.62	0.57
BALANCED ACCURACY AT 0.01% FPR								
Llama 3.3 70B	0.50	0.41	0.72	0.50	0.89	0.48	0.57	0.58
Qwen 2.5 72B	0.50	0.50	—	0.50	0.57	—	—	0.52
Mistral 3.1 24B	0.50	0.50	—	0.50	0.70	0.50	0.53	0.54
Gemma 3 27B	—	—	0.50	—	0.50	—	0.50	0.50
Average	0.50	0.47	0.61	0.50	0.67	0.49	0.53	0.54
RECALL								
Llama 3.3 70B	0.11	0.37	0.70	0.42	1.00	0.47	0.90	0.57
Qwen 2.5 72B	0.00	0.00	—	0.00	1.00	—	—	0.25
Mistral 3.1 24B	0.98	0.00	—	0.96	1.00	0.00	0.97	0.65
Gemma 3 27B	—	—	0.00	—	0.16	—	0.96	0.37
Average	0.37	0.12	0.35	0.46	0.79	0.24	0.94	0.47
RECALL AT 0.1% FPR								
Llama 3.3 70B	0.00	0.00	0.50	0.02	1.00	0.00	0.36	0.27
Qwen 2.5 72B	0.00	0.00	—	0.00	0.92	—	—	0.23
Mistral 3.1 24B	0.35	0.00	—	0.33	0.83	0.00	0.67	0.36
Gemma 3 27B	—	—	0.00	—	0.01	—	0.25	0.09
Average	0.12	0.00	0.25	0.12	0.69	0.00	0.43	0.23
RECALL AT 0.01% FPR								
Llama 3.3 70B	0.00	0.00	0.43	0.00	1.00	0.00	0.13	0.22
Qwen 2.5 72B	0.00	0.00	—	0.00	0.19	—	—	0.05
Mistral 3.1 24B	0.00	0.00	—	0.00	0.50	0.00	0.07	0.10
Gemma 3 27B	—	—	0.00	—	0.01	—	0.00	0.00
Average	0.00	0.00	0.22	0.00	0.43	0.00	0.07	0.10
FPR AT 1% FPR								
Llama 3.3 70B	0.10	0.84	0.51	0.28	0.25	0.78	0.58	0.48
Qwen 2.5 72B	0.00	0.00	—	0.00	0.43	—	—	0.11
Mistral 3.1 24B	0.97	0.00	—	0.53	0.34	0.00	1.00	0.47
Gemma 3 27B	—	—	0.00	—	0.08	—	0.87	0.32
Average	0.36	0.28	0.25	0.27	0.28	0.39	0.81	0.38

Table 8: Results for Upper Bound Probe at a 1% false-positive rate on alpaca. The values in the AVERAGE column are computed by first aggregating across models and then across datasets.

Model (all instruction-tuned)	Dataset							AVERAGE
HP-C	HP-KR	CG	ST	ID	GS	IT		
BALANCED ACCURACY								
Llama 3.3 70B	0.67	0.95	1.00	—	0.90	—	0.93	0.89
Qwen 2.5 72B	0.51	0.53	0.76	—	0.59	—	0.74	0.62
Mistral 3.1 24B	0.65	0.91	0.99	—	0.82	—	0.86	0.85
Gemma 3 27B	0.50	0.50	0.68	—	0.52	—	0.52	0.54
Average	0.58	0.72	0.86	—	0.71	—	0.76	0.73
AUROC								
Llama 3.3 70B	0.74	0.97	1.00	—	0.95	—	0.99	0.93
Qwen 2.5 72B	0.71	0.97	1.00	—	0.93	—	0.98	0.92
Mistral 3.1 24B	0.72	0.96	1.00	—	0.93	—	0.98	0.92
Gemma 3 27B	0.70	0.94	1.00	—	0.87	—	0.96	0.89
Average	0.72	0.96	1.00	—	0.92	—	0.98	0.91
RECALL								
Llama 3.3 70B	0.84	0.97	1.00	—	0.98	—	0.97	0.95
Qwen 2.5 72B	0.02	0.06	0.52	—	0.20	—	0.47	0.25
Mistral 3.1 24B	0.44	0.88	0.98	—	0.75	—	0.74	0.76
Gemma 3 27B	0.00	0.00	0.36	—	0.04	—	0.04	0.09
Average	0.32	0.48	0.71	—	0.49	—	0.56	0.51
FPR								
Llama 3.3 70B	0.50	0.08	0.00	—	0.18	—	0.12	0.18
Qwen 2.5 72B	0.00	0.00	0.00	—	0.02	—	0.00	0.00
Mistral 3.1 24B	0.13	0.06	0.00	—	0.12	—	0.01	0.06
Gemma 3 27B	0.00	0.00	0.00	—	0.00	—	0.00	0.00
Average	0.16	0.03	0.00	—	0.08	—	0.03	0.06

Table 9: Results for Self-Evaluation at a 1% false-positive rate on alpaca. The values in the AVERAGE column are computed by first aggregating across models and then across datasets.

Model (all instruction-tuned)	Dataset							AVERAGE
	HP-C	HP-KR	CG	ST	ID	GS	IT	
AUROC								
Llama 3.3 70B	0.69	0.44	0.95	0.87	0.99	0.49	0.93	0.76
Qwen 2.5 72B	0.50	0.50	—	0.76	0.98	—	—	0.69
Mistral 3.1 24B	0.63	0.51	—	0.74	0.78	0.52	0.62	0.63
Gemma 3 27B	—	—	0.93	0.95	0.97	—	0.72	0.89
Average	0.61	0.49	0.94	0.83	0.93	0.50	0.75	0.72
BALANCED ACCURACY AT 1% FPR								
Llama 3.3 70B	0.55	0.49	0.79	0.86	0.98	0.48	0.58	0.68
Qwen 2.5 72B	0.50	0.50	—	0.76	0.97	—	—	0.68
Mistral 3.1 24B	0.54	0.50	—	0.66	0.76	0.48	0.54	0.58
Gemma 3 27B	—	—	0.89	0.83	0.93	—	0.69	0.83
Average	0.53	0.50	0.84	0.78	0.91	0.48	0.60	0.66
BALANCED ACCURACY AT 0.1% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.50	0.50	—	0.76	0.85	—	—	0.65
Mistral 3.1 24B	0.52	0.50	—	0.58	0.73	0.48	0.49	0.55
Gemma 3 27B	—	—	0.64	0.55	0.96	—	0.50	0.66
Average	0.51	0.50	0.57	0.60	0.76	0.49	0.50	0.56
BALANCED ACCURACY AT 0.01% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.50	0.50	—	0.50	0.50	—	—	0.50
Mistral 3.1 24B	0.50	0.50	—	0.50	0.50	0.50	0.50	0.50
Gemma 3 27B	—	—	0.50	0.50	0.50	—	0.50	0.50
Average	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
RECALL								
Llama 3.3 70B	0.13	0.05	0.58	0.80	0.98	0.05	0.16	0.39
Qwen 2.5 72B	0.00	0.01	—	0.58	0.94	—	—	0.38
Mistral 3.1 24B	0.10	0.00	—	0.38	0.59	0.00	0.35	0.24
Gemma 3 27B	—	—	0.86	0.68	1.00	—	0.73	0.82
Average	0.08	0.02	0.72	0.61	0.88	0.03	0.41	0.39
RECALL AT 0.1% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.00	0.00	—	0.57	0.70	—	—	0.32
Mistral 3.1 24B	0.04	0.00	—	0.18	0.52	0.00	0.02	0.13
Gemma 3 27B	—	—	0.28	0.11	0.99	—	0.00	0.35
Average	0.01	0.00	0.14	0.22	0.55	0.00	0.01	0.13
RECALL AT 0.01% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.00	0.00	—	0.00	0.00	—	—	0.00
Mistral 3.1 24B	0.00	0.00	—	0.00	0.00	0.00	0.00	0.00
Gemma 3 27B	—	—	0.00	0.00	0.00	—	0.00	0.00
Average	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
FPR AT 1% FPR								
Llama 3.3 70B	0.02	0.07	0.00	0.08	0.02	0.09	0.00	0.04
Qwen 2.5 72B	0.00	0.00	—	0.06	0.00	—	—	0.02
Mistral 3.1 24B	0.02	0.00	—	0.07	0.07	0.04	0.27	0.08
Gemma 3 27B	—	—	0.08	0.03	0.14	—	0.34	0.15
Average	0.01	0.02	0.04	0.06	0.06	0.06	0.20	0.07