

Table 10: Results for LLM-as-a-Judge at a 1% false-positive rate on alpaca. The values in the AVERAGE column are computed by first aggregating across models and then across datasets.

Model (all instruction-tuned)	Dataset							AVERAGE
	HP-C	HP-KR	CG	ST	ID	GS	IT	
AUROC								
Llama 3.3 70B	0.76	0.48	1.00	0.93	0.99	0.45	0.96	0.80
Qwen 2.5 72B	0.76	0.62	—	0.93	0.99	—	—	0.83
Mistral 3.1 24B	0.79	0.79	—	0.93	0.99	0.44	0.96	0.82
Gemma 3 27B	—	—	0.98	0.97	0.99	—	0.95	0.97
Average	0.77	0.63	0.99	0.94	0.99	0.45	0.96	0.82
BALANCED ACCURACY AT 1% FPR								
Llama 3.3 70B	0.63	0.50	1.00	0.88	0.98	0.45	0.89	0.76
Qwen 2.5 72B	0.55	0.48	—	0.88	0.86	—	—	0.69
Mistral 3.1 24B	0.71	0.56	—	0.88	0.96	0.48	0.90	0.75
Gemma 3 27B	—	—	0.72	0.81	0.86	—	0.72	0.78
Average	0.63	0.52	0.86	0.86	0.91	0.46	0.84	0.73
BALANCED ACCURACY AT 0.1% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.51	0.50	—	0.78	0.66	—	—	0.61
Mistral 3.1 24B	0.50	0.50	—	0.50	0.50	0.50	0.50	0.50
Gemma 3 27B	—	—	0.50	0.50	0.50	—	0.50	0.50
Average	0.50	0.50	0.50	0.57	0.54	0.50	0.50	0.52
BALANCED ACCURACY AT 0.01% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.50	0.50	—	0.50	0.50	—	—	0.50
Mistral 3.1 24B	0.50	0.50	—	0.50	0.50	0.50	0.50	0.50
Gemma 3 27B	—	—	0.50	0.50	0.50	—	0.50	0.50
Average	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
RECALL								
Llama 3.3 70B	0.37	0.07	0.99	0.85	0.98	0.03	0.99	0.61
Qwen 2.5 72B	0.17	0.02	—	0.81	0.72	—	—	0.43
Mistral 3.1 24B	0.66	0.16	—	0.84	0.92	0.07	0.95	0.60
Gemma 3 27B	—	—	0.45	0.62	0.72	—	0.46	0.56
Average	0.40	0.08	0.72	0.78	0.84	0.05	0.80	0.52
RECALL AT 0.1% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.03	0.00	—	0.58	0.32	—	—	0.23
Mistral 3.1 24B	0.00	0.00	—	0.00	0.00	0.00	0.00	0.00
Gemma 3 27B	—	—	0.00	0.00	0.00	—	0.00	0.00
Average	0.01	0.00	0.00	0.14	0.08	0.00	0.00	0.03
RECALL AT 0.01% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.00	0.00	—	0.00	0.00	—	—	0.00
Mistral 3.1 24B	0.00	0.00	—	0.00	0.00	0.00	0.00	0.00
Gemma 3 27B	—	—	0.00	0.00	0.00	—	0.00	0.00
Average	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
FPR AT 1% FPR								
Llama 3.3 70B	0.11	0.07	0.00	0.09	0.02	0.14	0.20	0.09
Qwen 2.5 72B	0.07	0.05	—	0.06	0.00	—	—	0.04
Mistral 3.1 24B	0.23	0.03	—	0.09	0.01	0.11	0.15	0.10
Gemma 3 27B	—	—	0.01	0.00	0.01	—	0.01	0.01
Average	0.14	0.05	0.00	0.06	0.01	0.13	0.12	0.07

Table 11: Results for Unrelated Question Classifier at a 1% false-positive rate on alpaca. The values in the AVERAGE column are computed by first aggregating across models and then across datasets.

Model (all instruction-tuned)	Dataset							
	HP-C	HP-KR	CG	ST	ID	GS	IT	AVERAGE
AUROC								
Llama 3.3 70B	0.75	0.90	0.69	0.92	0.94	0.43	0.91	0.79
Qwen 2.5 72B	0.71	0.97	—	0.83	0.94	—	—	0.86
Mistral 3.1 24B	0.50	0.58	—	0.71	0.88	0.48	0.46	0.60
Gemma 3 27B	—	—	0.87	0.88	0.95	—	0.94	0.91
Average	0.65	0.82	0.78	0.83	0.93	0.46	0.77	0.75
BALANCED ACCURACY AT 1% FPR								
Llama 3.3 70B	0.55	0.56	0.53	0.80	0.89	0.50	0.79	0.66
Qwen 2.5 72B	0.53	0.50	—	0.77	0.80	—	—	0.65
Mistral 3.1 24B	0.50	0.50	—	0.53	0.83	0.51	0.53	0.57
Gemma 3 27B	—	—	0.54	0.50	0.85	—	0.56	0.61
Average	0.53	0.52	0.53	0.65	0.84	0.51	0.63	0.60
BALANCED ACCURACY AT 0.1% FPR								
Llama 3.3 70B	0.51	0.51	0.61	0.70	0.90	0.50	0.69	0.63
Qwen 2.5 72B	0.51	0.50	—	0.72	0.87	—	—	0.65
Mistral 3.1 24B	0.50	0.50	—	0.53	0.83	0.51	0.53	0.57
Gemma 3 27B	—	—	0.54	0.50	0.85	—	0.56	0.61
Average	0.51	0.50	0.57	0.61	0.86	0.50	0.59	0.59
BALANCED ACCURACY AT 0.01% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.50	0.50	—	0.50	0.50	—	—	0.50
Mistral 3.1 24B	0.50	0.50	—	0.50	0.50	0.50	0.50	0.50
Gemma 3 27B	—	—	0.50	0.50	0.50	—	0.50	0.50
Average	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
RECALL								
Llama 3.3 70B	0.13	0.12	0.40	0.68	1.00	0.05	0.88	0.47
Qwen 2.5 72B	0.09	0.00	—	0.71	1.00	—	—	0.45
Mistral 3.1 24B	0.00	0.00	—	0.08	1.00	0.06	0.10	0.21
Gemma 3 27B	—	—	0.08	0.00	0.78	—	0.12	0.24
Average	0.08	0.04	0.24	0.37	0.94	0.06	0.36	0.30
RECALL AT 0.1% FPR								
Llama 3.3 70B	0.04	0.01	0.40	0.44	1.00	0.00	0.39	0.33
Qwen 2.5 72B	0.01	0.00	—	0.47	0.98	—	—	0.37
Mistral 3.1 24B	0.00	0.00	—	0.08	1.00	0.06	0.10	0.21
Gemma 3 27B	—	—	0.08	0.00	0.78	—	0.12	0.24
Average	0.02	0.00	0.24	0.25	0.94	0.03	0.20	0.24
RECALL AT 0.01% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.00	0.00	—	0.00	0.00	—	—	0.00
Mistral 3.1 24B	0.00	0.00	—	0.00	0.00	0.00	0.00	0.00
Gemma 3 27B	—	—	0.00	0.00	0.00	—	0.00	0.00
Average	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
FPR AT 1% FPR								
Llama 3.3 70B	0.04	0.01	0.35	0.08	0.23	0.04	0.29	0.15
Qwen 2.5 72B	0.03	0.00	—	0.17	0.40	—	—	0.15
Mistral 3.1 24B	0.00	0.00	—	0.02	0.34	0.05	0.05	0.08
Gemma 3 27B	—	—	0.00	0.00	0.08	—	0.00	0.02
Average	0.02	0.00	0.17	0.07	0.26	0.05	0.11	0.10

Table 12: Results for Self-Evaluation (alternative prompt to judge deceptiveness) at a 1% false-positive rate on alpaca. The values in the AVERAGE column are computed by first aggregating across models and then across datasets.

Model (all instruction-tuned)	Dataset							AVERAGE
	HP-C	HP-KR	CG	ST	ID	GS	IT	
AUROC								
Llama 3.3 70B	0.70	0.37	0.96	0.86	0.99	0.57	0.86	0.76
Qwen 2.5 72B	0.53	0.52	—	0.75	0.98	—	—	0.69
Mistral 3.1 24B	0.52	0.49	—	0.74	0.90	0.55	0.61	0.64
Gemma 3 27B	—	—	0.83	—	0.94	—	0.74	0.84
Average	0.58	0.46	0.89	0.78	0.95	0.56	0.74	0.71
BALANCED ACCURACY AT 1% FPR								
Llama 3.3 70B	0.52	0.49	0.75	0.84	0.97	0.54	0.66	0.68
Qwen 2.5 72B	0.52	0.51	—	0.75	0.96	—	—	0.68
Mistral 3.1 24B	0.51	0.50	—	0.68	0.86	0.50	0.58	0.60
Gemma 3 27B	—	—	0.76	—	0.93	—	0.73	0.81
Average	0.52	0.50	0.76	0.75	0.93	0.52	0.66	0.66
BALANCED ACCURACY AT 0.1% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.52	0.50	—	0.75	0.94	—	—	0.68
Mistral 3.1 24B	0.51	0.50	—	0.66	0.85	0.50	0.58	0.60
Gemma 3 27B	—	—	0.76	—	0.93	—	0.73	0.81
Average	0.51	0.50	0.63	0.64	0.81	0.50	0.60	0.60
BALANCED ACCURACY AT 0.01% FPR								
Llama 3.3 70B	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
Qwen 2.5 72B	0.50	0.50	—	0.50	0.50	—	—	0.50
Mistral 3.1 24B	0.50	0.50	—	0.50	0.50	0.50	0.50	0.50
Gemma 3 27B	—	—	0.50	—	0.50	—	0.50	0.50
Average	0.50	0.50	0.50	0.50	0.50	0.50	0.50	0.50
RECALL								
Llama 3.3 70B	0.06	0.01	0.50	0.73	0.97	0.12	0.33	0.39
Qwen 2.5 72B	0.07	0.02	—	0.55	0.92	—	—	0.39
Mistral 3.1 24B	0.10	0.00	—	0.49	0.77	0.01	0.60	0.33
Gemma 3 27B	—	—	0.69	—	1.00	—	0.74	0.81
Average	0.08	0.01	0.59	0.59	0.91	0.06	0.56	0.40
RECALL AT 0.1% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.07	0.01	—	0.55	0.89	—	—	0.38
Mistral 3.1 24B	0.08	0.00	—	0.43	0.76	0.01	0.51	0.30
Gemma 3 27B	—	—	0.69	—	1.00	—	0.74	0.81
Average	0.05	0.00	0.35	0.33	0.66	0.00	0.42	0.26
RECALL AT 0.01% FPR								
Llama 3.3 70B	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Qwen 2.5 72B	0.00	0.00	—	0.00	0.00	—	—	0.00
Mistral 3.1 24B	0.00	0.00	—	0.00	0.00	0.00	0.00	0.00
Gemma 3 27B	—	—	0.00	—	0.00	—	0.00	0.00
Average	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
FPR AT 1% FPR								
Llama 3.3 70B	0.01	0.04	0.00	0.05	0.02	0.05	0.02	0.03
Qwen 2.5 72B	0.02	0.01	—	0.06	0.01	—	—	0.02
Mistral 3.1 24B	0.08	0.00	—	0.14	0.06	0.00	0.43	0.12
Gemma 3 27B	—	—	0.16	—	0.14	—	0.28	0.19
Average	0.04	0.01	0.08	0.08	0.06	0.02	0.24	0.08